

Coaching mi-juin — DataValueXploring

Étape roadmap : « *Analyse des résultats, prise de recul, mise en valeur* »

Projet : réduire durablement les accidents de la route par la rénovation d'infrastructure. **Rôle incarné** : agence de voirie / DOT d'une collectivité. **Données** : *US Accidents* (Kaggle), Feb 2016 → Mar 2023, **7,73 M accidents**, 49 États. **Date** : 22/06/2026.

0. Où on en est sur la roadmap

Jalon	Date prévue	État
Lancement SAE	22/04	✓
Analyse préliminaire (faisable / deuils / spécificité du rôle)	~08/05	✓
Choix techniques + 1 ^{re} pipeline fonctionnelle	~24/05	✓
Analyse des résultats, prise de recul, mise en valeur	mi-juin	◀ nous sommes ici
Livraison & présentation	début juillet	🕒

Depuis le dernier coaching, on est passé de « pipeline qui tourne » à « **pipeline qui produit des résultats exploitables, validés et explicables** », le tout dans **un notebook unique reproductible** (rendu/notebook.ipynb) qui s'exécute de bout en bout sans intervention sur les 7,73 M lignes (données auto-téléchargées via `kagglehub`).

1. Rappel du cadrage (1 min)

On décline le fil rouge « *où et quoi rénover avec un budget limité ?* » en 3 questions :

Question	Nature	Méthode
OÙ rénover en priorité ?	descriptif	agrégation géospatiale H3 + exposition OSM
QUOI installer sur place ?	ML (moteur de preuve)	modèle de gravité → SHAP → prescription conditionnelle
QUAND activer des mesures temporaires ?	descriptif	patterns temporels / météo / événements

Principe directeur : on ne livre **pas** un prédicteur. On entraîne un modèle de gravité **comme microscope** : on l'interroge (SHAP) pour savoir quels éléments structurels aggravent → donc quoi corriger. **La prédiction est le moyen ; l'explication est le livrable.**

2. Mise en valeur des résultats

2.1 OÙ — le risque est très concentré et stable dans le temps

- Sur la Californie (démonstration) : **1,74 M accidents** → **58 857 zones** (H3 rés. 8, ~0,7 km²).

- **Concentration** : les **50 zones prioritaires** (0,08 % des zones) concentrent **5,3 % de la charge** totale → **~62x leur part équitable**. Rénover quelques zones a un effet de levier réel.
- **Validation de robustesse (nouveau)** : en coupant 2016-2019 vs 2020-2023, la corrélation de rang des scores est **Spearman $\rho = 0,776$** , et **les 50 zones prioritaires restent toutes dans le top 5 %** sur la 2^e période → le risque est **structurel**, pas du bruit conjoncturel.
- **Exposition OSM** (« dangereux ou juste fréquenté ? ») : pour le top des zones, on récupère la longueur de voirie + nb d'intersections et on calcule **accidents/km**. Le re-classement fait **remonter de vrais points noirs concentrés** masqués par le volume (ex. une zone passe **+11 rangs** après normalisation).

2.2 QUOI — modèle de gravité honnête, puis explication

Comparaison de 5 modèles (même split temporel, même métrique) — *on ne se fie pas à l'accuracy (trompeuse à 80/20)* :

Modèle	PR-AUC	ROC-AUC	Rappel « grave »
Dummy (plancher)	0,064	0,500	0,00
Régression logistique	0,110	0,635	0,63
Arbre de décision	0,079	0,560	0,68
Random Forest	0,115	0,646	0,63
HistGradientBoosting 	0,125	0,676	0,57

- Tous **battent le plancher** ; meilleur = HistGB (**x2 vs plancher**). Performance **modeste et assumée** : prédire la gravité d'un accident à partir du seul contexte infra/météo/heure est intrinsèquement difficile (vitesse réelle, comportement = absents). **C'est cohérent avec notre thèse : le modèle est un révélateur de leviers, pas un oracle.**
- **Analyse des erreurs (nouveau)** : matrice de confusion + courbes PR. Au seuil 0,5, **44 % des accidents graves sont ratés** (faux négatifs) → on explique l'arbitrage seuil ↔ fausses alertes (un grave raté = un point noir non détecté).
- **Convergence inter-modèles (nouveau)** : logistique, arbre, forêt et SHAP **classent les leviers d'infra dans le même ordre** → diagnostic robuste, indépendant du choix de modèle.

2.3 QUAND — des résultats contre-intuitifs (valeur différenciante)

- **Météo** : part de graves dans une fourchette étroite (~~16–23 %~~). ~~Le brouillard affiche la part la plus basse (16 %) — à l'opposé du common knowledge — probablement par conduite prudente ; pluie/ciel couvert légèrement au-dessus (22–23 %).~~
- **Jours fériés** : la sévérité **ne s'emballe pas** (sév. moyenne quasi plate 2,18–2,25) ; **Noël/Nouvel An est même plus bas** (15,5 % vs 19,5 % en période normale).
- **Lecture métier** : la météo et le calendrier relèvent du risque **conjoncturel** → mesures **dynamiques** (panneaux à messages variables), pas la rénovation structurelle. On les **visualise**, on ne les met pas au cœur du modèle.

2.4 Synthèse décisionnelle (le livrable pour le décideur)

- `zones_prioritaires.csv` + carte Folium : **par zone**, où + quoi installer + **impact estimé**, **trié par impact** = ordre d'intervention.

- **Recommandations variées** (pas un aménagement unique partout) grâce à l'effet **conditionnel** : sécuriser passage piéton, passage à niveau, stop/cédez, modération de trafic, installer feux... + zones « facteur humain » signalées honnêtement.

3. Prise de recul — ce qui marche / ce qui ne marche pas

Ce qui marche

- Priorisation **objective et défendable** (indépendante des accidents médiatisés).
- **Convergence des preuves** : aléa local (lift descriptif) ↔ contributions SHAP (modèle) ↔ stabilité temporelle.
- L'exposition OSM corrige le biais « beaucoup d'accidents = beaucoup de routes ».

Ce qui ne marche pas / reste incertain

- **Pouvoir prédictif modéré** (PR-AUC 0,125) — assumé : on prédit pour expliquer, pas pour prédire.
- **Piège d'interprétation maîtrisé** : en SHAP global, feux/passages/stops ressortent *aggravants* — **artefact de confusion** (ils marquent les carrefours denses). D'où une prescription fondée sur l'**effet conditionnel** $\Delta(\text{mesure} \mid \text{aléa local})$, pas l'effet moyen.
- **Zones « diffuses »** sans levier infra dominant → renvoyées au facteur humain (affiché, pas masqué).

Deuils & limites assumés

- **Pas de causalité** (pas de panel avant/après) → associations, pas preuves d'efficacité.
- **Biais de reporting** MapQuest/Bing (couverture inégale ; Top 3 États ≈ 41 % du dataset).
- Pas de profil conducteur ni de coût réel (`severity` = seul proxy).
- **Exposition OSM partielle (13/50 zones)** : l'API Overpass nous a throttlés → le reste est classé par volume (dégradation propre, documentée). Coverable plus tard.

4. Auto-évaluation vs grille critériée

Compétence	Niveau visé	Appui
Concevoir	Dépasse	enjeu → data/ML cadré, arbitrages & deuils explicites, démarche EDA→modèle→validation→valorisation.
Formaliser	Dépasse	valeur actionnable (CSV+carte+impact), EDA riche avec signaux non triviaux.
Produire	Attendu solide	Spark, code factorisé, reproductible, tests d'intégrité + anti-fuite , métriques honnêtes, erreurs analysées. Restes : tests pytest/Docker, OSM complet.

5. Prochaines étapes → livraison (début juillet)

1. **OSM complet** sur les 50 zones (quand Overpass coopère) pour une exposition exhaustive.
2. (Bonus « Dépasse » côté Produire) **suite pytest** sur fonctions extraites + **Dockerfile** (Java/Spark encapsulés).
3. (Optionnel) **K-fold temporelle** en complément du split unique.

4. Préparer la **soutenance** : dérouler le fil OÙ → QUOI → QUAND + la décision terrain « *que fait le DOT lundi matin* ».

Question pour le coach : on a privilégié la **profondeur d'analyse et l'explicabilité** (cœur de la valeur métier) plutôt que l'industrialisation (tests formels / Docker). Est-ce le bon arbitrage au regard des attendus, ou faut-il rééquilibrer vers le volet « Produire » d'ici la livraison ?